

Evaluation of a Depth-Augmented ACT Model for Humanoid Manipulation

Abstract—Modelos Vision-Language-Action (VLA) têm emergido como um paradigma promissor para controle generalista de robôs, explorando a capacidade de raciocínio semântico de modelos fundacionais de larga escala. Entretanto, arquiteturas VLA padrão dependem predominantemente de entradas RGB 2D, carecendo da consciência geométrica explícita que caracteriza o controle sensorio-motor biológico — especificamente, a visão estereoscópica essencial para apreensão preditiva. Neste trabalho, investigamos se a integração explícita de percepção de profundidade pode aumentar a eficiência de aquisição de habilidades de políticas de aprendizado por imitação em regimes de poucos dados. Avaliamos uma variante da arquitetura Action Chunking with Transformers (ACT) com incorporação de profundidade, adotando a metodologia de codificador geométrico baseada em PointNet proposta em 3D-CAVLA [1] para fundir características 3D densas com tokens visuais e proprioceptivos. Para validar essa abordagem, aprimoramos um framework de teleoperação de alta fidelidade para o robô humanoide Unitree G1, incorporando uma nova estratégia de controle denominada “Pinch Retargeting” e feedback estereoscópico, resultando em um conjunto de dados curado com 30 demonstrações de alta qualidade para uma tarefa de pick-and-place. Em contraste com a hipótese de que priors geométricos facilitaríamos adaptação rápida, nossos experimentos revelam um modo crítico de falha denominado Mean Action Collapse. Tanto as políticas de base (apenas RGB) quanto as com profundidade convergiram para a trajetória média do conjunto de dados, atingindo uma taxa de sucesso de apenas 10% e efetivamente ignorando o condicionamento visual durante a inferência. Atribuímos esse comportamento ao colapso posterior do CVAE, agravado pela extrema escassez de dados ($N = 30$) e forte regularização. Este estudo contribui com um blueprint arquitetural validado para VLAs conscientes de 3D e um pipeline robusto de coleta de dados com humanoides, além de demonstrar empiricamente que a codificação geométrica explícita, por si só, é insuficiente para superar o gargalo de generalização inerente ao treinamento de transformers de alta capacidade do zero com conjuntos de dados pequenos.

Index Terms—VLA, Imitation Learning, Humanoid Robots, AGI.

I. INTRODUÇÃO

A definição e o desenvolvimento da Inteligência Artificial Geral (AGI) têm sido temas de intenso debate ao longo das últimas décadas. Enquanto a Inteligência Artificial Restrita (ANI) é caracterizada pela proficiência em um conjunto limitado de tarefas pré-definidas, a AGI implica uma capacidade de generalização extrema — a habilidade de transferir aprendizado para diversos domínios distintos sem retreinamento específico para cada tarefa.

Nos últimos anos, sistemas de ANI igualaram ou superaram o desempenho humano em verticais específicas. Exemplos notáveis incluem reconhecimento de imagens com ResNet

[2], Reconhecimento Automático de Fala (ASR) com Whisper [3], e capacidades diversas em jogos demonstradas pela série Alpha da DeepMind [4], [5]. Além disso, Modelos de Linguagem de Grande Escala (LLMs), como a série GPT [6]–[9], demonstraram que conhecimento cultural geral e padrões de raciocínio podem emergir a partir da escala.

Esses avanços desafiam marcos históricos. O Teste de Turing [10], outrora considerado o padrão-ouro para inteligência, é hoje amplamente visto como insuficiente para AGI. LLMs conseguem imitar efetivamente a geração de texto humano, frequentemente enganando avaliadores humanos, mas podem carecer de um modelo de mundo subjacente [11] ou de compreensão causal, ambos necessários para uma inteligência verdadeiramente geral. Para lidar com essa limitação, o campo tem migrado para definições formais fundamentadas em teoria da informação e adaptação.

Legg e Hutter [12] sintetizaram definições informais em uma medida formal de Inteligência Universal, $\Upsilon(\pi)$, que avalia a capacidade de um agente de maximizar recompensas em uma ampla gama de ambientes:

$$\Upsilon(\pi) := \sum_{\mu \in E} 2^{-K(\mu)} V_{\mu}^{\pi}.$$

Onde $K(\mu)$ representa a complexidade de Kolmogorov do ambiente, atribuindo maior peso a ambientes mais simples. Embora teoricamente elegante, essa definição depende de funções incomputáveis. Consequentemente, definições práticas passaram a enfatizar eficiência. Chollet [13] define inteligência não como habilidade estática, mas como eficiência de aquisição de habilidades — a capacidade de converter priors e experiência em novas habilidades. Ele distingue entre:

- **Robustez:** Adaptação a incógnitas conhecidas dentro de uma única tarefa.
- **Flexibilidade:** Adaptação a incógnitas desconhecidas entre tarefas relacionadas.
- **Generalidade:** Adaptação a incógnitas desconhecidas em domínios ilimitados.

Em nenhum lugar a lacuna entre inteligência textual e realidade física é mais evidente do que na robótica. O “Teste da Xícara de Café” de Wozniak ilustra esse desafio: um sistema verdadeiramente inteligente deveria ser capaz de entrar em uma cozinha aleatória e desconhecida e preparar uma xícara de café. Isso requer Flexibilidade e Incorporação (Embodiment) — o agente deve perceber um mundo não estruturado, raciocinar sobre affordances (por exemplo, identificar uma chaleira desconhecida) e manipular objetos dinamicamente.

Tradicionalmente, a robótica abordou esses problemas por meio de pipelines modulares: estimação explícita de estado, planejamento e leis de controle projetadas para hardware específico. Embora o aprendizado profundo tenha melhorado componentes individuais — como percepção via ResNet [2] ou detecção de objetos via YOLO [14] — a integração permaneceu frágil e específica para tarefas.

A. Modelos Vision-Language-Action (VLAs)

Para reduzir a lacuna entre compreensão semântica e controle físico, surgiu um novo paradigma: os Modelos Vision-Language-Action (VLAs). Inspirados pelo sucesso das LLMs, as VLAs propõem que o controle robótico não precisa ser uma disciplina de engenharia separada, mas pode ser formulado como um problema de modelagem de sequências.

Nessa arquitetura, imagens, instruções textuais e ações do robô são unificadas em um único fluxo multimodal de tokens. Assim como uma LLM prevê a próxima palavra, uma VLA prevê o próximo token de ação (por exemplo, pose do efetuador final ou posição das juntas) condicionado às entradas visuais e textuais. Trabalhos iniciais como o RT-2 [15] demonstraram que essa abordagem permite que robôs herdem o conhecimento semântico de dados em escala web. Ao explorar esse pré-treinamento, VLAs podem processar sinônimos e formulações complexas, ganhando flexibilidade para interpretar e obedecer a diversos comandos em linguagem natural sem depender de estruturas rígidas de comando.

O estado da arte atual concentra-se em escalar esses modelos fundacionais para a robótica, visando criar um “cérebro” generalista capaz de controlar diferentes incorporações físicas. Esse cenário expandiu-se rapidamente, dominado por iniciativas de pesos abertos como Octo [16], OpenVLA [17], o eficiente SmoVLA [18], os modelos π_0 e $\pi_{0.5}$ da Physical Intelligence [19], [20], e a série NVIDIA GR00T [21]–[23]. Em contraste, o Helix da Figure AI [24] permanece como uma das poucas arquiteturas de alto desempenho com pesos fechados. Baseando-se nas fundações de múltiplas incorporações do RT-X [25], esses modelos exploram pré-treinamento massivo em dados diversos da internet (vídeos, texto) e em conjuntos de dados multi-robô (como o Open X-Embodiment). Diferentemente do aprendizado por imitação tradicional, que frequentemente sofre de “esquecimento espúrio” de conceitos semânticos, essa abordagem alcança ampla generalização entre plataformas físicas distintas.

B. Integração Multimodal e Inspiração Biológica

Embora VLAs de larga escala tenham demonstrado impressionante generalização semântica, a transição de “ver e descrever” para “ver e manipular” impõe desafios que transcendem a visão computacional 2D. A inteligência biológica sugere que manipulação robusta não é resultado de um único sensor de alta fidelidade, mas do produto da fusão sensorial, especificamente da interação entre visão estereoscópica para planejamento e tato para controle.

A literatura neurofisiológica estabelece que a visão binocular (estereopsia) é um requisito crítico para o *controle preditivo*

feedforward da preensão. Pesquisas [26] indicam que a perda de estereopsia prejudica a programação das forças de preensão e da cinemática de alcance, forçando o sistema motor a depender de correções de erro guiadas por feedback, mais lentas [26]. Além disso, na ausência de pistas precisas de profundidade, humanos adotam uma “estratégia cautelosa”, caracterizada por margens de segurança infladas — como aberturas de preensão exageradas e fases de desaceleração prolongadas — para compensar a incerteza geométrica [27].

Enquanto a visão domina a fase de transporte, a fase de interação é governada pelo sistema somatossensorial. Johansson [28] propôs que a manipulação destreza é organizada em torno de eventos mecânicos discretos (por exemplo, contato, levantamento) codificados por aferências táteis. Isso valida a necessidade de feedback tátil para verificar a conclusão de tarefas e modular forças sob oclusão visual.

Consequentemente, depender apenas de entradas RGB monoculares — como visto em arquiteturas VLA iniciais como RT-1 ou OpenVLA — introduz um “gargalo sensorial”. Trabalhos recentes buscaram mitigar isso integrando modalidades de profundidade e tato ao paradigma VLA:

- **Integração de Profundidade:** Projetos como *VoxPoser* [29] e *3D-VLA* [30] demonstram que representações 3D explícitas (por exemplo, mapas voxelizados ou nuvens de pontos) permitem ao modelo ancorar conceitos semânticos em restrições geométricas. Isso replica efetivamente a função biológica da estereopsia, possibilitando “modelagem generativa de mundo”, onde o agente pode imaginar resultados 3D para planejamento zero-shot.
- **Integração Tátil:** Arquiteturas como *OmniVTLA* [31] e *Tactile-VLA* [32] incorporam codificadores táteis alinhados a tokens visuais. Esses modelos mostram que o feedback háptico é indispensável para tarefas ricas em contato, permitindo que o robô ajuste forças de preensão dinamicamente e manipule objetos deformáveis quando a estimativa visual falha.

Motivado por esses princípios biológicos e avanços arquiteturais, este projeto adota uma abordagem multimodal. Nossos episódios registrados incluem visão RGB egocêntrica, pares estado-ação das juntas, informações de profundidade e dados táteis. No escopo deste artigo, analisamos especificamente o impacto da integração de dados de profundidade na flexibilidade e na taxa de sucesso de tarefas de manipulação, testando a hipótese de que consciência geométrica (análoga à estereopsia biológica) é um pré-requisito para aquisição eficiente de habilidades. Embora dados táteis tenham sido coletados, sua integração fica reservada para análises futuras de dinâmicas ricas em contato. Outros sensores, como IMUs e microfones, foram excluídos do escopo atual por fornecerem utilidade marginal para o planejamento geométrico de manipulação com base fixa, em comparação com as contribuições críticas de visão e profundidade.

C. Contribuições deste Trabalho

Este artigo investiga se essas arquiteturas VLA fornecem a Flexibilidade necessária para passar em uma versão sim-

plificada do Teste da Xícara de Café. Nossa hipótese é que VLAs pré-treinados, ao explorarem seus massivos “priors” semânticos, demonstrarão maior eficiência de aquisição de habilidades do que políticas treinadas do zero.

Comparamos uma política de base treinada via Aprendizado por Imitação tradicional (ACT) com uma versão modificada para a inclusão de um token representando a profundidade. Utilizando um robô humanoide Unitree G1, avaliamos a capacidade dos modelos de generalizar uma tarefa de “pegar uma chaleira” para orientações novas e poses iniciais distintas do robô, utilizando o framework de eficiência de Chollet para quantificar sua inteligência.

II. TRABALHOS RELACIONADOS

A. Modelos Fundacionais Vision-Language-Action

O paradigma dos modelos Vision-Language-Action (VLA) alterou fundamentalmente o aprendizado robótico, deslocando o foco de engenharia específica por tarefa para modelos fundacionais generalistas. Trabalhos iniciais como RT-1 [33] e RT-2 [15] demonstraram que transformers de larga escala podem unificar visão, linguagem e tokenização de ações em uma única política fim a fim. Avanços recentes têm se concentrado em arquiteturas com pesos abertos e ajuste fino eficiente. O OpenVLA [17] utiliza a backbone Llama 2 com codificadores visuais DINOv2 e SigLIP para alcançar forte generalização no conjunto de dados Open X-Embodiment. Paralelamente, arquiteturas como SmolVLA [18] e π_0 [19] utilizam cabeças baseadas em flow-matching e difusão para lidar com espaços de ação contínuos de forma mais eficaz do que a tokenização discreta. Entretanto, esses modelos fundacionais dependem predominantemente de entradas RGB 2D, frequentemente apresentando dificuldades em tarefas que exigem compreensão espacial precisa, como preensão de objetos com profundidades ambíguas ou navegação em ambientes desordenados [34].

B. Adaptação Geométrica e Integração de Profundidade

Para abordar a “lacuna de raciocínio espacial” dos VLAs baseados apenas em 2D, pesquisas recentes têm explorado a integração de profundidade explícita e geometria 3D.

- **Integração com Planejamento Externo:** Abordagens iniciais como o **VoxPoser** [29] não inseriam dados 3D diretamente na política, mas utilizavam LLMs para gerar código que construía mapas de valores voxelizados em 3D para planejadores de movimento a jusante.
- **Modelos Generativos de Mundo:** O **3D-VLA** [30] introduziu uma abordagem generativa, prevendo futuras nuvens de pontos 3D para guiar a interação, funcionando efetivamente como um modelo de mundo. Embora poderoso, esse método acarreta sobrecarga computacional significativa.
- **Codificadores Geométricos (PointNet/Injeção):** A tendência mais relevante para este trabalho envolve o aumento de VLAs com codificadores geométricos explícitos e leves. O **GeoVLA** [35] propõe uma Point Embedding Network (PEN) para extrair características geométricas de mapas de profundidade em paralelo à backbone VLM.

De forma semelhante, o **FALCON** [36] injeta tokens espaciais 3D diretamente na cabeça de ação para preservar a integridade semântica do VLM pré-treinado. Mais próximo à nossa metodologia, o **3D-CAVLA** [1] emprega explicitamente um codificador PointNet para processar informações de profundidade, fundindo contexto 3D com tokens visuais para melhorar significativamente as taxas de sucesso em tarefas de manipulação não vistas.

Nosso trabalho se alinha a essa última categoria, empregando um codificador baseado em PointNet para fundir informações de profundidade, validando a eficiência dessa arquitetura para manipulação de precisão.

C. Percepção Tátil e Multimodal

Além da geometria, a integração de modalidades ricas em contato é uma fronteira em crescimento. **Tactile-VLA** [32] e **OmniVTLA** [31] demonstraram que a fusão de leituras táteis (por meio de codificadores dedicados) com tokens visuais permite que robôs modulem forças e manipulem objetos deformáveis. Embora nossa análise atual foque em profundidade, nosso pipeline de coleta de dados inclui modalidades táteis, posicionando nosso sistema para se estender a esse domínio multimodal em trabalhos futuros.

III. METODOLOGIA

Para avaliar o impacto da percepção geométrica explícita na manipulação robótica, projetamos um estudo comparativo envolvendo o modelo *Action Chunking with Transformers* (ACT) [37]. O pipeline experimental consiste em três fases: (1) coleta de dados de alta fidelidade por meio de um framework aprimorado de teleoperação em VR, (2) treinamento de base de políticas utilizando apenas RGB, e (3) treinamento de variantes aumentadas com profundidade, utilizando um codificador PointNet adaptado da arquitetura 3D-CAVLA [1]. Ambos os modelos foram avaliados *in-domain* em uma tarefa de “pegar uma chaleira”, com poses do objeto randomizadas.

A. Coleta de Dados e Teleoperação

Utilizamos um robô humanoide Unitree G1 equipado com mãos Dex3-1 de três dedos. Para possibilitar a coleta de um conjunto de dados multimodal, modificamos o pipeline de registro de dados do repositório oficial de teleoperação da Unitree¹. Enquanto o código original registrava apenas estados das juntas e imagens RGB, nossa modificação permite a captura síncrona de fluxos RGB-D (cor e profundidade) e dados de sensores táteis, juntamente com a propriocepção do robô.

1) **Sistema de Feedback Visual Estereoscópico:** Um fator crítico na qualidade da teleoperação é a percepção de profundidade fornecida ao operador. Realizamos experimentos preliminares utilizando a câmera Realsense D435i montada na cabeça do robô, mas encontramos limitações significativas:

- 1) **RGB Planar:** A transmissão de vídeo 2D padrão para o headset de VR resultou em baixa capacidade de julgamento de profundidade e pouca imersão.

¹https://github.com/unitreerobotics/xr_teleoperate

- 2) **Estéreo Sintetizado:** Tentativas de combinar fluxos RGB e profundidade (por exemplo, modulando a matriz pela profundidade ou enviando RGB para o olho esquerdo e o mapa de profundidade para o direito) causaram forte rivalidade binocular e náusea no operador, devido à ausência de disparidade estereoscópica real.

Para resolver esse problema, instalamos uma câmera de rastreamento Intel RealSense T265 na cabeça do robô. Diferentemente de câmeras RGB convencionais, a T265 fornece um fluxo estéreo sincronizado de câmeras *fisheye*, com baixa latência e amplo campo de visão (FOV). Transmitimos essas imagens duais diretamente para os displays esquerdo e direito do headset Meta Quest 3. Embora isso limite o feedback visual à escala de cinza, o sistema fornece estereopsia real e alta taxa de quadros, mitigando efetivamente o enjoo de simulador e permitindo manobras espaciais precisas.

2) **Estratégia de Controle: Pinch Retargeting:** Outro desafio na teleoperação de mãos antropomórficas dexterosas é o descompasso cinemático entre o operador humano e o efetuador final do robô. A implementação padrão, baseada no Dex-Pilot (AnyTeleop [38]), resolve um problema de otimização que, em nossos testes, restringiu o espaço de trabalho da mão Dex3-1, impedindo a extensão completa dos dedos.

Para contornar esse problema, introduzimos uma heurística simplificada denominada *Pinch Retargeting*. Esse método mapeia a abertura funcional da mão humana diretamente para o espaço de juntas do robô, reduzindo o problema de controle a dois graus de liberdade principais: abertura da mão (d_{TI}) e oposição do polegar (d_{TM}). Esse mapeamento é detalhado no Algoritmo 1.

Algorithm 1 Estratégia de *Pinch Retargeting*

Require: Lado da Mão $S \in \{Esquerda, Direita\}$, Entradas de Referência

- 1: **Parâmetros:** $D_{max} \leftarrow 0,10$ m (Limite virtual de abertura)
 - 2: **Constantes:** Limites das juntas Q_{min}^S, Q_{max}^S
 - 3: {Calcula fatores de interpolação normalizados (0 a 1)}
 - 4: $\alpha_{TI} \leftarrow \text{Clip}(d_{TI}/D_{max}, 0, 1)$
 - 5: $\alpha_{TM} \leftarrow \text{Clip}(d_{TM}/D_{max}, 0, 1)$
 - 6: {Interpola linearmente os dedos com base na abertura (α_{TI})}
 - 7: $\mathbf{q} \leftarrow \mathbf{Q}_{min}^S + \alpha_{TI}(\mathbf{Q}_{max}^S - \mathbf{Q}_{min}^S)$
 - 8: {Controle independente da rotação do polegar ($j = 0$) usando α_{TM} }
 - 9: $q_0 \leftarrow Q_{min,0}^S + \alpha_{TM}(Q_{max,0}^S - Q_{min,0}^S)$
 - 10: **return** Configuração alvo das juntas $\mathbf{q}$
-

Adaptação para Controle em VR: Embora o Algoritmo 1 tenha sido originalmente projetado para rastreamento de mãos baseado em visão, a redução do espaço de controle para duas dimensões possibilitou uma interface mais robusta. Verificamos que mapear os parâmetros α_{TI} e α_{TM} para os gatilhos analógicos e joysticks do controle de VR ofereceu maior estabilidade ergonômica em comparação com o rastreamento contínuo da mão livre, que frequentemente sofre




Fig. 1. Distribuição das notas de qualidade das demonstrações (Likert 1–5) utilizadas na filtragem pós-hoc.

com oclusões e fadiga. Consequentemente, o conjunto de dados final foi coletado utilizando essa estratégia de Pinch Retargeting controlada por joystick.

Protocolo de Coleta: Os dados foram coletados por um único operador especialista para garantir consistência da política. O robô permaneceu fixo em frente a uma mesa, enquanto o objeto alvo (chaleira) foi instanciado em poses variadas, porém alcançáveis, envolvendo tanto deslocamentos planares aleatórios quanto rotações azimutais. Para garantir que a política aprendesse uma geração de trajetórias robusta, em vez de superajustar a um único vetor de abordagem, o operador variou explicitamente a configuração inicial do braço no início de cada episódio. Um episódio era considerado bem-sucedido quando o robô agarrava firmemente a alça e levantava a chaleira, deixando-a completamente fora da superfície da mesa.

Filtragem e Validação dos Dados: Inicialmente, coletamos 39 demonstrações bem-sucedidas. Para garantir alta qualidade dos dados, esses episódios passaram por uma avaliação qualitativa pós-hoc realizada por um avaliador humano. Cada demonstração recebeu uma nota em uma escala Likert de 1 a 5, em que 5 representa uma execução fluida e ótima, e 1 representa uma execução bem-sucedida, porém subótima (por exemplo, hesitação, contatos desnecessários ou movimentos bruscos). Como mostrado na Figura 1, a distribuição das notas evidenciou um subconjunto de trajetórias subótimas. Apenas demonstrações com nota maior ou igual a 3 foram mantidas, resultando em um conjunto de dados final curado com 30 demonstrações de alta qualidade. Esse conjunto de dados foi convertido para o formato LeRobot [37] para padronização².

B. Arquiteturas e Treinamento

Avaliamos o ACT e comparamos os resultados do baseline (apenas RGB) com uma variante aumentada com profundidade.

Metodologia de Integração de Profundidade (3D-CAVLA): Para incorporar informações de profundidade, ado-

²O conjunto de dados será disponibilizado publicamente após a aceitação




Fig. 2. Visão geral da arquitetura do Action Chunking Transformer (ACT) com aprimoramento por profundidade, adaptada para o humanoide Unitree G1. A política combina observações multimodais: (A) imagens RGB são codificadas por um backbone ResNet-18 e achatadas em tokens visuais (300×512); (B) imagens de profundidade são explicitamente retroprojetadas em nuvens de pontos densas ($N \approx 307k$ pontos) e processadas por um codificador PointNet para extrair um embedding geométrico global invariante à permutação (1×512); (C) o estado proprioceptivo do robô é projetado por meio de um MLP. Esses embeddings, combinados com uma variável latente z de um CVAE (durante o treinamento), são integrados pelo Transformer Encoder-Decoder para prever um bloco temporalmente coerente de ações futuras ($k = 100$) para os 28 graus de liberdade do robô.

tamos a arquitetura de codificador específica proposta em 3D-CAVLA [1]. Utilizamos a implementação open-source dos autores, que processa a imagem de profundidade por meio de: (1) retroprojeção em uma nuvem de pontos densa, (2) alinhamento por meio de uma Spatial Transformer Network (STN) e (3) extração de um vetor global de características geométricas utilizando um backbone PointNet. Esse vetor é projetado para a dimensão de embedding do modelo e injetado como um token distinto na sequência de entrada. A Figura 2 apresenta a arquitetura completa do modelo.

1) *Configurações de Treinamento:* Tanto o ACT Vanilla quanto o ACT com aumento de profundidade foram treinados em um único nó com NVIDIA A100 (80 GB de VRAM). Para garantir uma comparação justa, todos os hiperparâmetros e divisões de dados permaneceram idênticos entre os experimentos. Apenas o backbone de imagem (ResNet-18) foi inicializado com pesos pré-treinados no ImageNet (primeiras 4 camadas); o restante da arquitetura foi treinado do zero.

Utilizamos batch size de 8 e o otimizador AdamW [39] com $\beta_1 = 0.9$, $\beta_2 = 0.99$, $\epsilon = 10^{-8}$ e weight decay de 10^{-4} .

A taxa de aprendizado foi definida como 10^{-5} , com dropout de 0.1 e clipping da norma do gradiente em 10. Para action chunking, o horizonte de predição foi definido como $k = 100$. O objetivo do CVAE incluiu um peso de divergência KL de $\beta = 10$, penalizando a variável latente por se desviar do prior $\mathcal{N}(\mathbf{0}, \mathbf{I})$.

O conjunto de dados de 30 episódios foi dividido na proporção 80/10/10 para treinamento, validação e teste. Dado o tamanho do conjunto de dados e a estratégia de batching, uma época de treinamento corresponde a aproximadamente 1.380 passos de otimização. Os modelos foram treinados por no máximo 20 épocas, com cerca de 8 avaliações por época. No entanto, como mostrado nos resultados, a convergência foi atingida significativamente antes do limite de 20 épocas, com a loss estabilizando nas primeiras épocas. Consequentemente, as curvas de loss apresentadas na Seção IV focam nessa fase ativa de aprendizado.

2) *Estratégia Latente do CVAE e Protocolo de Avaliação:* Uma característica arquitetural crítica do ACT é sua formulação como um Autoencoder Variacional Condicional (CVAE). Durante o treinamento, um Transformer Encoder (o Encoder do CVAE) comprime a sequência de ações ground-truth e o estado do robô em uma variável latente de “estilo” z . A política (Decoder) então condiciona nesse z , juntamente com as observações visuais, para reconstruir as ações.

Entretanto, durante a execução no mundo real (inferência), as ações ground-truth não estão disponíveis, e a variável de estilo é fixada na média do prior (o vetor nulo, $z = \mathbf{0}$). Isso introduz um dilema metodológico para a validação:

- **Avaliação Posterior (usando o Encoder):** Fornecer as ações ground-truth de validação ao encoder do CVAE gera um z que captura o “estilo” específico da demonstração. Embora isso produza uma loss de reconstrução matematicamente menor, há vazamento de informação sobre a ação esperada, potencialmente mascarando a incapacidade da política de controlar o robô baseando-se apenas em pistas visuais.
- **Avaliação no Prior (com $z = \mathbf{0}$ fixo):** Isso replica as condições rigorosas da execução real. Embora inevitavelmente resulte em valores de loss maiores, é a única métrica que representa fielmente a capacidade do modelo de agir de forma autônoma.

Existe um risco conhecido no treinamento de CVAEs em que o decoder passa a depender excessivamente das informações ricas contidas em z (o problema de “posterior collapse” ou “atalho de informação”), ignorando efetivamente as entradas de imagem e estado. Quando isso ocorre, o modelo atinge baixa loss de treinamento, mas falha de forma catastrófica no momento da inferência, quando z é zerado.

Para avaliar rigorosamente essa capacidade de generalização e evitar vazamento de dados, proibimos estritamente o uso do encoder de estilo durante a validação. Todas as métricas de validação reportadas neste trabalho foram computadas utilizando $z = \mathbf{0}$, garantindo que o desempenho apresentado reflita a dependência do modelo nas entradas RGB/Profundidade, e não na variável latente de estilo.

3) *Objetivo de Treinamento*: O modelo é treinado de ponta a ponta para minimizar uma função de perda composta por um termo de reconstrução e um termo de regularização. A loss de reconstrução $\mathcal{L}_{recon}$ é o Erro Absoluto Médio (L1) entre a sequência de ações prevista $\hat{\mathbf{a}}_{t:t+k}$ e a demonstração ground-truth $\mathbf{a}_{t:t+k}$:

$$\mathcal{L}_{recon} = \frac{1}{k} \sum_{i=0}^{k-1} \|\hat{\mathbf{a}}_{t+i} - \mathbf{a}_{t+i}\|_1 \quad (1)$$

Para estruturar o espaço latente, impomos a regularização do CVAE minimizando a divergência de Kullback-Leibler (KL) entre a distribuição posterior aprendida $q_\phi(z|\mathbf{x})$ (parametrizada pelas saídas do encoder μ e σ^2) e um prior Gaussiano padrão $p(z) = \mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$\mathcal{L}_{KL} = D_{KL}(q_\phi(z|\mathbf{x})\|p(z)) = -\frac{1}{2} \sum_{j=1}^{D_z} (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2) \quad (2)$$

O objetivo total de treinamento é a soma ponderada desses dois termos:

$$\mathcal{L}_{total} = \mathcal{L}_{recon} + \beta \mathcal{L}_{KL} \quad (3)$$

Em nossos experimentos, definimos $\beta = 10$. Esse peso elevado no termo KL incentiva o modelo a aprender um espaço latente suave e compacto, mas, como discutido nos resultados, pode contribuir para o posterior collapse em regimes com poucos dados, ao forçar a variável latente a ignorar informações condicionantes em favor do prior.

C. Protocolo de Avaliação

Para avaliar a robustez e a capacidade de generalização das políticas aprendidas, projetamos um protocolo de avaliação controlado dentro da mesma distribuição (in-distribution). A configuração experimental física — incluindo condições de iluminação, altura da mesa e posição da base do robô — permaneceu consistente com a fase de coleta de dados, a fim de isolar o impacto das variações geométricas.

Definição da Tarefa: O robô deve localizar uma chaleira posicionada sobre a mesa, agarrá-la firmemente pela alça e levantá-la verticalmente. A tarefa é considerada iniciada quando o robô está em sua posição inicial e a chaleira está colocada sobre a superfície da mesa.

Randomização e Justiça Experimental: Avaliamos a generalização a variações espaciais randomizando a pose da chaleira (x, y, θ) em cada tentativa. Para garantir uma comparação estrita um-para-um entre arquiteturas (por exemplo, Baseline RGB vs. com Profundidade), geramos previamente um conjunto de 10 configurações espaciais aleatórias. Todos os modelos foram avaliados exatamente nesse mesmo conjunto de 10 poses, eliminando variações de dificuldade da tarefa entre execuções. Essas poses foram amostradas da mesma distribuição dos dados de treinamento, mas não foram vistas durante o treinamento.

Métrica de Sucesso: Reportamos a **Taxa de Sucesso (SR)**, definida como a porcentagem de tentativas em que o robô

consegue levantar o objeto completamente da mesa e mantê-lo suspenso por pelo menos 2 segundos sem escorregar. Qualquer tentativa em que o robô falhe em agarrar, derrube o objeto ou o deixe cair durante o levantamento é registrada como falha.

Modo de Inferência: Durante a avaliação, as políticas operam de forma autônoma em malha fechada. Crucialmente, como discutido nas Configurações de Treinamento, a variável latente do CVAE é fixada na média do prior ($z = \mathbf{0}$).

IV. RESULTADOS

Avaliamos as políticas em um cenário dentro da distribuição (in-distribution), com poses da chaleira randomizadas. Um episódio é considerado bem-sucedido quando o robô levanta a chaleira completamente da superfície da mesa. Conduzimos 10 tentativas de avaliação por modelo.

A. Desempenho Quantitativo

Tanto o ACT Vanilla quanto o ACT com aumento de profundidade atingiram uma taxa de sucesso de **10%** (1/10 tentativas). O único sucesso em ambos os casos ocorreu quando a chaleira foi posicionada na posição média (centro do espaço de trabalho), coincidindo com a média estatística da distribuição de treinamento.

B. Análise da Loss e Modos de Falha

As Figuras 3 e 4 ilustram a dinâmica de treinamento. Ambos os modelos apresentam convergência rápida da loss de treinamento (L1 + KL), estabilizando em torno de 8000 passos. Entretanto, a loss de validação atinge um platô precocemente, sugerindo que os modelos tiveram dificuldade em generalizar para variações não vistas no conjunto de validação.

Análise Comportamental: A inspeção qualitativa das execuções malsucedidas revela um fenômeno de **Colapso para a Ação Média**. Independentemente da entrada visual (RGB ou Profundidade), o robô executou uma trajetória estereotipada em direção ao centro do espaço de trabalho, fechou a garra e tentou levantar. Esse comportamento indica que a política ignorou o condicionamento visual e colapsou para prever a trajetória média do conjunto de dados.

- **Ignorar o Visual**: A similaridade nos modos de falha entre os modelos RGB e RGB-D sugere que o problema não está na *qualidade* das características visuais (já que o PointNet fornece geometria explícita), mas sim na *utilização* dessas características pelo Transformer.
- **Colapso do Posterior vs. da Política**: Embora o objetivo de treinamento do CVAE (ELBO) tenha sido minimizado, o alto peso KL ($\beta = 10$) provavelmente forçou o espaço latente em direção ao prior $\mathcal{N}(\mathbf{0}, \mathbf{I})$ de forma excessivamente agressiva. Combinado com o pequeno tamanho do conjunto de dados (30 episódios), o decoder provavelmente considerou mais fácil ignorar os tokens visuais complexos e depender apenas do estado proprioceptivo e das ações médias aprendidas para minimizar a loss de reconstrução.




Fig. 3. Loss de treinamento e validação para o ACT Vanilla. O platô precoce na loss de validação indica generalização limitada.




Fig. 4. Loss de treinamento e validação para o ACT com profundidade. O platô precoce na loss de validação indica generalização limitada.

V. DISCUSSÃO

Os resultados experimentais destacam um desafio crítico no treinamento de modelos VLA de alta capacidade: o gargalo de eficiência de dados.

O Papel da Escala do Conjunto de Dados: Resultados de ponta com ACT normalmente utilizam 50+ demonstrações para tarefas simples ou centenas para manipulação complexa. Nosso conjunto de dados curado com 30 episódios, embora de alta qualidade (filtrado via escala Likert), mostrou-se insuficiente para que o Transformer aprendesse um mapeamento robusto de latentes visuais de alta dimensionalidade para ações. O “Colapso para a Ação Média” observado é um modo de falha conhecido em aprendizado por imitação quando o suporte da distribuição de treinamento é muito esparsa para cobrir efetivamente o espaço de estados.

Eficácia da Integração de Profundidade: Embora o codificador PointNet tenha processado com sucesso as informações de profundidade, seus benefícios foram anulados pela tendência da política de ignorar completamente os tokens visuais. Isso sugere que simplesmente injetar características geométricas não é uma “solução mágica” em regimes com poucos dados. Para que a profundidade seja efetiva, a política precisa primeiro aprender a dar atenção às pistas visuais, o que

exige diversidade de dados suficiente para penalizar estratégias “cegas”.

Direções Futuras: Para desbloquear o potencial da arquitetura proposta com aumento de profundidade, trabalhos futuros devem focar em:

- **Ajuste de Arquitetura:** Reduzir a capacidade do Transformer do ACT ou diminuir o peso KL para evitar o posterior collapse que leva ao comportamento de ação média.
- **Melhoria do Modelo:** Utilizar VLAs pré-treinados em conjuntos de dados robóticos de larga escala.

VI. CONCLUSÃO

Neste trabalho, exploramos a integração de percepção geométrica explícita em modelos Vision-Language-Action (VLA) para manipulação com robôs humanoides. Avaliamos uma arquitetura aumentada com profundidade que combina um codificador baseado em PointNet com o Action Chunking Transformer (ACT), permitindo que a política processe nuvens de pontos 3D densas juntamente com dados RGB e proprioceptivos. Para validar essa abordagem, aprimoramos um pipeline de teleoperação para o robô Unitree G1, incorporando uma estratégia inédita de “Pinch Retargeting” e visualização estereoscópica, resultando em um conjunto de dados curado com 30 demonstrações de alta qualidade.

Nossa avaliação experimental revelou um insight crítico sobre a interação entre capacidade do modelo e escala de dados. Embora o modelo com profundidade tenha convergido com sucesso durante o treinamento, tanto a política baseline quanto a aumentada apresentaram “Colapso para a Ação Média” durante a inferência, alcançando uma taxa de sucesso de apenas 10%. Esse modo de falha evidencia que incorporar características geométricas ricas (via PointNet) é insuficiente para superar o gargalo de generalização inerente ao treinamento de Transformers de alta capacidade em conjuntos de dados de pequena escala ($N=30$). A forte regularização ($\beta = 10$) provavelmente agravou esse problema, levando o decoder do CVAE a desconsiderar os tokens visuais em favor de um comportamento de busca por modo centrado na média do conjunto de dados.

Apesar da baixa taxa de sucesso, este estudo contribui com um blueprint arquitetural validado para VLAs sensíveis a 3D e um framework robusto de coleta de dados para robôs humanoides. Nossos achados indicam que esforços futuros devem priorizar a ampliação do conjunto de demonstrações em uma ordem de grandeza, além de explorar valores menores de β ou estratégias de pré-treinamento para evitar o posterior collapse. Em última análise, reduzir a lacuna entre “ver” a geometria e “agir” com base nela requer não apenas melhores codificadores, mas um regime de dados que obrigue a política a depender deles.

REFERENCES

- [1] V. Bhat, Y.-H. Lan, P. Krishnamurthy, R. Karri, and F. Khorrami, “3d-cavla: Leveraging depth and 3d context to generalize vision language action models for unseen tasks,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2025, arXiv:2505.05800.

- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [3] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," 2022. [Online]. Available: <https://arxiv.org/abs/2212.04356>
- [4] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot *et al.*, "Mastering the game of go with deep neural networks and tree search," *Nature*, vol. 529, no. 7587, pp. 484–489, 2016.
- [5] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel *et al.*, "A general reinforcement learning algorithm that masters chess, shogi, and go through self-play," *Science*, vol. 362, no. 6419, pp. 1140–1144, 2018.
- [6] A. Radford, K. Narasimhan, T. Salimans, and I. Sutskever, "Improving language understanding by generative pre-training," 2018.
- [7] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever, "Language models are unsupervised multitask learners," *OpenAI blog*, vol. 1, no. 8, p. 9, 2019.
- [8] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.
- [9] OpenAI, "Gpt-4 technical report," *arXiv preprint arXiv:2303.08774*, 2023. [Online]. Available: <https://arxiv.org/abs/2303.08774>
- [10] A. M. Turing, "Computing machinery and intelligence," *Mind*, vol. 59, no. 236, pp. 433–460, 1950.
- [11] Y. LeCun, "A path towards autonomous machine intelligence," *OpenReview*, vol. 62, 2022. [Online]. Available: <https://openreview.net/forum?id=BZSa1r-kVsf>
- [12] S. Legg and M. Hutter, "Universal intelligence: A definition of machine intelligence," *Minds and Machines*, vol. 17, no. 4, pp. 391–444, 2007.
- [13] F. Chollet, "On the measure of intelligence," *arXiv preprint arXiv:1911.01547*, 2019. [Online]. Available: <https://arxiv.org/abs/1911.01547>
- [14] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 779–788.
- [15] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid *et al.*, "Rt-2: Vision-language-action models transfer web knowledge to robotic control," in *Proceedings of the 7th Conference on Robot Learning*. PMLR, 2023, pp. 2165–2183.
- [16] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch *et al.*, "Octo: An open-source generalist robot policy," in *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [17] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, P. Sanketi, Q. Vuong *et al.*, "Openvla: An open-source vision-language-action model," in *Proceedings of the 8th Conference on Robot Learning (CoRL)*, 2024. [Online]. Available: <https://arxiv.org/abs/2406.09246>
- [18] M. Shukor, D. Aubakirova, F. Capuano *et al.*, "Smolvla: A vision-language-action model for affordable and efficient robotics," *arXiv preprint arXiv:2506.01844*, 2025. [Online]. Available: <https://arxiv.org/abs/2506.01844>
- [19] Physical Intelligence, K. Black, N. Brown, J. Darpinian, D. Driess, C. Finn, K. Hausman, B. Ichter, S. Levine *et al.*, " π_0 : A vision-language-action flow model for general robot control," *arXiv preprint arXiv:2410.24164*, 2024. [Online]. Available: <https://www.pi.website/research/pi0>
- [20] Physical Intelligence, K. Black, U. Zhilinsky *et al.*, " $\pi_{0.5}$: A vision-language-action model with open-world generalization," *arXiv preprint arXiv:2504.16054*, 2025. [Online]. Available: <https://arxiv.org/abs/2504.16054>
- [21] A. Mandlkar, L. Fan, Y. Zhu, T. Voyager, and NVIDIA GEAR, "Gr00t n1: An open foundation model for generalist humanoid robots," *arXiv preprint arXiv:2503.14734*, 2025. [Online]. Available: <https://arxiv.org/abs/2503.14734>
- [22] NVIDIA GEAR, "Gr00t n1.5: An improved open foundation model for generalist humanoid robots," NVIDIA Research, Tech. Rep., 2025. [Online]. Available: https://research.nvidia.com/labs/gear/gr00t-n1_5/
- [23] NVIDIA GEAR, E. Llonatop, Y. Chang, and Y. Deng, "Gr00t n1.6: An improved open foundation model for generalist humanoid robots," NVIDIA Research, Tech. Rep., 2026. [Online]. Available: https://research.nvidia.com/labs/gear/gr00t-n1_6/
- [24] Figure AI, "Helix: A vision-language-action model for generalist humanoid control," <https://www.figure.ai/news/helix>, 2025, technical Release.
- [25] Open X-Embodiment Collaboration, "Open x-embodiment: Robotic learning datasets and rt-x models," in *IEEE International Conference on Robotics and Automation (ICRA)*, 2024, pp. 1–15.
- [26] E. Niechwiej-Szwedo, H. C. Goltz, M. Chandrakumar, Z. Hirji, J. D. Crawford, and A. M. F. Wong, "Effects of anisometric amblyopia on visuomotor behavior, part 2: Visually guided reaching," *Investigative Ophthalmology & Visual Science*, vol. 52, no. 2, pp. 795–803, 2011.
- [27] D. R. Melmoth and S. Grant, "Advantages of binocular vision for the control of reaching and grasping," *Experimental Brain Research*, vol. 171, no. 3, pp. 371–388, 2006.
- [28] R. S. Johansson and J. R. Flanagan, "Coding and use of tactile signals from the fingertips in object manipulation tasks," *Nature Reviews Neuroscience*, vol. 10, no. 5, pp. 345–359, 2009.
- [29] W. Huang, C. Wang, R. Zhang, Y. Li, J. Wu, and L. Fei-Fei, "Voxposer: Composable 3d value maps for robotic manipulation with language models," in *Proceedings of the 7th Conference on Robot Learning (CoRL)*, vol. 229. PMLR, 2023, pp. 540–562.
- [30] H. Zhen, X. Qiu, P. Chen, J. Yang, X. Yan, Y. Du, Y. Hong, and C. Gan, "3d-vla: A 3d vision-language-action generative world model," in *Forty-first International Conference on Machine Learning (ICML)*, 2024.
- [31] Z. Cheng, Y. Zhang, W. Zhang, H. Li, K. Wang, L. Song, and H. Zhang, "OmniVla: Vision-tactile-language-action model with semantic-aligned tactile sensing," *arXiv preprint arXiv:2508.08706*, 2025.
- [32] J. Huang, S. Wang, F. Lin, Y. Hu, C. Wen, and Y. Gao, "Tactile-vla: Unlocking vision-language-action model's physical knowledge for tactile generalization," *arXiv preprint arXiv:2507.09160*, 2025.
- [33] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. Ryoo, G. Salazar, P. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, "Rt-1: Robotics transformer for real-world control at scale," in *arXiv preprint arXiv:2212.06817*, 2022.
- [34] K. Kawaharazuka, J. Oh, J. Yamada, I. Posner, and Y. Zhu, "Vision-language-action models for robotics: A review towards real-world applications," *IEEE Access*, 2025, arXiv:2510.07077.
- [35] J. Sun *et al.*, "Geovla: Empowering 3d representations in vision-language-action models," *arXiv preprint arXiv:2508.09071*, 2025.
- [36] Y. Fu *et al.*, "From spatial to actions: Grounding vision-language-action model in spatial foundation priors," *arXiv preprint arXiv:2510.17439*, 2025.
- [37] R. Cadene, S. Alibert, A. Soare, Q. Gallouedec, A. Zouitine, S. Palma, P. Kooijmans, M. Aractingi, M. Shukor, D. Aubakirova, M. Russi, F. Capuano, C. Pascal, J. Choghari, J. Moss, and T. Wolf, "Lerobot: State-of-the-art machine learning for real-world robotics in pytorch," <https://github.com/huggingface/lerobot>, 2024.
- [38] Y. Qin, W. Yang, B. Huang, K. Van Wyk, H. Su, X. Wang, Y.-W. Chao, and D. Fox, "Anyteleop: A general vision-based dexterous robot arm-hand teleoperation system," in *Robotics: Science and Systems*, 2023.
- [39] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," 2019. [Online]. Available: <https://arxiv.org/abs/1711.05101>